

Рецензия на статью

Levitt, S. D., List, J. A., Neckermann, S., & Sadoff, S. (2016). The Behavioralist Goes to School: Leveraging Behavioral Economics to Improve Educational Performance. *American Economic Journal: Economic Policy*, 8(4), 183–219.

В стандартной образовательной системе награды (оценки, аттестаты) отложены на годы, а ученики склонны к гиперболическому дисконтированию, что ведёт к недовложению усилий с их стороны. Авторы предлагают перепроектировать стимулы с опорой на три идеи поведенческой экономики. Во-первых, награда должна быть немедленной, во-вторых, фрейминг как проигрыш ощущается сильнее, чем выигрыш, в-третьих, нефинансовые стимулы (трофеи) могут быть эффективнее денег для некоторых групп.

Исследовательский вопрос этой работы можно сформулировать следующим образом: «Могут ли поведенческие стимулы, описанные выше, повысить усилия школьников при сдаче низкорисковых тестов (low-stakes tests; они не влияют на оценки в школе и не несут никаких последствий для учеников)?»

Авторами был проведён полевой эксперимент с участием более 5 700 учеников начальной, средней и старшей школы в трёх округах Чикаго (Bloom, Chicago Heights, CPS). Ученики писали компьютерный диагностический тест (STAR, ThinkLink, Scantron). Условие получения награды – улучшение собственного предыдущего результата. При этом варьировались сумма награды (10/20 долларов), тип награды (деньги/трофей), фрейминг (gain/loss), время выдачи (немедленно/через месяц). Рандомизация выборки состоит на уровне класса или всей школы.

Основные результаты:

- крупные и немедленные денежные стимулы (\$20) повышают баллы на 0.07–0.15 стандартного отклонения. Те же стимулы с задержкой в месяц не работают вообще;
- нефинансовые стимулы (трофеи примерно за \$3) эффективны у младших школьников и по эффекту сравнимы с \$20 для других групп;
- есть намёк на то, что фрейм «проигрыш» сильнее «выигрыша», но разница статистически не значима;
- маленькие стимулы (\$10) не работают и могут создавать негативные спилловеры на другие тесты;

- эффекты сильнее в тестах по математике (чем в тестах по чтению) и у мальчиков (чем у девочек).

Исследование вносит существенный вклад в развитие поведенческой экономики:

- первое систематическое тестирование «поведенческого пакета» в образовании. В отличие от предыдущих работ (Fryer 2011; Bettinger 2012), которые тестировали только денежные стимулы, эта статья одновременно проверяет три механизма: сдвиг к настоящему, непринятие потерь и эффект нефинансовых награды;

- дизайн с улучшением относительно собственного прошлого результата и коротким тестом (15–30 минут) позволяет утверждать, что рост баллов – это именно увеличение усилия и внимания, а не обучение новому материалу;

- авторы последовательно переходят от малого (Bloom, одна школа) к среднему (Chicago Heights, семь школ) и к крупному масштабу (CPS, 26 школ). Это позволяет обсуждать внешнюю валидность не умозрительно, а эмпирически;

- разрыв между немедленным и отложенным вознаграждением (причём задержка всего в месяц) является прямым свидетельством того, что дети «живут сегодняшним днём». Трофей за \$3 даёт тот же прирост, что и 20\$, то для школ с ограниченным бюджетом это практическая рекомендация.

Также хочется отметить особенно удачные элементы дизайна исследования:

- использование собственного прошлого результата как бенчмарка – элегантный способ сделать стимул достижимым и релевантным;

- наличие двух типов контроля (control-no statement и control-statement) позволяет отсеять эффект от простого присутствия экспериментаторов;

- три разные школьные системы (малый городской округ, пригород, мегаполис) – хорошая проверка внешней валидности и воспроизводимости.

И всё же, можно выделить несколько содержательных замечаний. Разберём их по порядку.

Замечание 1. Проблема множественного тестирования

Авторы проверяют десятки гипотез в различных спецификациях (разные волны, типы стимулов, подгруппы, исходы) с порогом $p < 0.05$ без каких-либо поправок. Даже с учётом зависимости между тестами (одни и те же люди, коррелированные исходы), множественные проверки повышают риск ложноположительных результатов. Классические поправки (Бонферрони, Холм) здесь были бы излишне консервативны, так как не учитывают корреляционную

структуру данных. Более корректным решением было бы применение перестановочных процедур (List, Shaikh, Xu, 2019), которые сохраняют зависимость между тестами и обеспечивают контроль FWER без катастрофического падения мощности.

Замечание 2. Смещение экстенсивной и интенсивной границ

Авторы интерпретируют АТЕ как «увеличение усилия». Однако рост среднего балла может идти за счёт двух разных каналов – переключение учеников из состояния «не старается» в «старается» (экстенсивная граница) или увеличение интенсивности у тех, кто и так старался (интенсивная граница). Без разложения эффекта (например, через two-part model или Lee bounds) утверждение о механизме остаётся недоказанным. Рекомендуется в будущих исследованиях разделять эти два канала.

Замечание 3. Причинная интерпретация гетерогенности

Авторы сравнивают эффекты между группами (пол, возраст, предмет) и делают выводы о том, кто «более чувствителен» к стимулам. Однако эти переменные не рандомизированы и могут коррелировать с ненаблюдаемыми факторами (например, базовые способности, мотивация, учитель, время проведения теста). Наблюдаемые различия – это CATE (условные средние эффекты), а не ATME (причинные эффекты модераторов). Рекомендуется чётко разделять описательную и каузальную интерпретацию, а при причинно-следственных утверждениях о модераторах использовать дизайны с рандомизацией модератора (где это возможно) или явно обосновывать условие conditional moderator independence.

Помимо замечаний, указанных выше, стоит обратить внимание на необъяснённую гетерогенность результатов во времени. В волне CPS Winter 2011 (Таблица 6, колонки 11-12) практически все значимые эффекты, найденные в предыдущих волнах, исчезают. Авторы честно признают, что не могут этого объяснить. Это ставит вопрос о стабильности поведенческих стимулов во времени и о потенциальной роли неучтённых ситуационных факторов (например, усталость от эксперимента, изменение восприятия экспериментаторов). Будущим репликациям следовало бы проверить, воспроизводится ли нулевой эффект в похожих условиях.

Статья Levitt et al. (2016) занимает уникальное место в литературе по стимулам в образовании. В отличие от Fryer (2011)¹, который не нашёл значимых эффектов денежных стимулов в трёх крупных RCT, Levitt et al. показывают, что при правильном дизайне (немедленность, достаточная сумма) денежные стимулы могут работать. Относительно Bettinger (2012)², где эффект нашёлся только на математике, Levitt et al. добавляют важный нюанс: стимулы влияют на усилие в момент теста, а не на накопленные знания, что объясняет, почему эффект сильнее на математике (более чувствительна к усилию). Наконец, Jalava et al. (2014)³ подтверждают, что нефинансовые стимулы (сертификаты, ранжирование) работают в скандинавском контексте, но Levitt et al. впервые систематически сравнивают их с денежными и демонстрируют, что трофеи могут быть эффективнее денег у младших школьников. Таким образом, статья усиливает вывод Jalava о нефинансовых стимулах, но ставит под сомнение нулевые результаты Fryer и Bettinger, показывая, что критика денежных стимулов относилась к их плохому дизайну (отложенность, маленькая сумма), а не к принципиальной неэффективности.

Исходя из статьи хочется выделить два возможных направления для дальнейших исследований. Во-первых, в текущей работе оценивается только общий эффект (ATE) на тестовый балл. Остаётся неясным, через какой именно канал стимулы повышают результаты — увеличение времени на вопрос, перепроверка ответов или снижение тревожности. Будущие исследования могут собирать компьютерные метаданные о поведении учеников и применять методы для декомпозиции ATE на прямой и косвенный эффекты. Во-вторых, Jalava et al. (2014) показали, что эффект ранжирования значительно слабее для учеников, которые не знакомы со способностями одноклассников. В статье Levitt et al. этот канал не анализируется, хотя их дизайн (особенно тритмент с публичным объявлением наград) предполагает социальные сравнения. Дальнейшие исследования могут включить переменную «peer familiarity» (длительность совместного обучения в классе) и проверить, усиливается ли эффект фрейминга потерь и нефинансовых стимулов в более знакомых группах.

¹ Fryer, R. G. (2011). Financial Incentives and Student Achievement: Evidence from Randomized Trials. *Quarterly Journal of Economics*, 126(4), 1755–1798.

² Bettinger, E. (2012). Paying to Learn: The Effect of Financial Incentives on Elementary School Test Scores. *Review of Economics and Statistics*, 94(3), 686–698.

³ Jalava, N., Joensen, J. S., & Pellas, E. (2014). Grades and rank: Impacts of non-financial incentives on test performance. *Journal of Economic Behavior & Organization*, 115, 161–196.

Работа Levitt et al. (2016) представляет собой важный шаг в применении поведенческой экономики к образованию, убедительно демонстрируя критическую роль немедленности стимулов. Однако отсутствие контроля множественных сравнений, смещение экстенсивной и интенсивной границ, а также причинная интерпретация гетерогенности без обоснования conditional moderator independence ограничивают надёжность отдельных выводов.